DLHLP HW2 Voice Conversion Report

組長 github id: PengWenChen
組員： 趙達軒、許博閔、陳玠妏、陳芃彣

HW2-1 (Auto-Encoder) (2.5%)

(1) 請以 Auto-Encoder 之方法實做 Voice conversion。如果同學不想重新刻一個 auto-encoder，可以試著利用這個repo的部分程式碼，達到實現出 auto-encoder。如果你是修改助教提供的 repo，請在 report 當中敘述你是如何更改原本程式碼，建議可以附上修改部分的截圖以利助教批閱；同時，果餓未有更動原本模型參數也請一併列出。如果你的 auto-encoder是自己刻的，那也請你簡單敘述你的實作方法，並附上對應程式碼的截圖。(1%)

由於題目其中一個要求為 combine two speaker 的聲音，因此我們修改了 decoder 的部份，將 decoder 原本的 speaker embedding 改成相加除以二。將 hps 中的 n_speaker 改為 2。其餘部份直接使用 repo 中原本題供的 Encoder 和 Decoder，並將未使用到的 model 架構註解掉，最後把 loss 改成只有 reconstruction loss.

```
406   def forward2(self, x, c1, c2):
407       # conv layer
408       out = self.conv_block(x, [self.conv1, self.conv2], self.ins_norm1, (self.emb1(c1)+self.emb1(c2))/2, res=True )
409       out = self.conv_block(out, [self.conv3, self.conv4], self.ins_norm2, (self.emb2(c1)+self.emb2(c2))/2, res=True)
410       out = self.conv_block(out, [self.conv5, self.conv6], self.ins_norm3, (self.emb3(c1)+self.emb3(c2))/2, res=True)
411       # dense layer
412       out = self.dense_block(out, (self.emb4(c1)+self.emb4(c2))/2, [self.dense1, self.dense2], self.ins_norm4, res=True)
413       out = self.dense_block(out, (self.emb4(c1)+self.emb4(c2))/2, [self.dense3, self.dense4], self.ins_norm5, res=True)
414       emb = (self.emb5(c1)+self.emb5(c2))/2
415       out_add = out + emb.view(emb.size(0), emb.size(1), 1)
416       # rnn layer
417       out_rnn = RNN(out_add, self.RNN)
418       out = torch.cat([out, out_rnn], dim=1)
419       out = append_emb((self.emb5(c1)+self.emb5(c2))/2, out.size(2), out)
420       out = linear(out, self.dense5)
421       out = F.leaky_relu(out, negative_slope=self.ns)
422       out = linear(out, self.linear)
423       #out = torch.tanh(out)
424       return out
```

```
39    if args.train:
40        #solver.train(args.output_model_path, args.flag, mode='pretrain_G')
41        #solver.train(args.output_model_path, args.flag, mode='pretrain_D')
42        solver.train(args.output_model_path, args.flag, mode='train')
43        #solver.train(args.output_model_path, args.flag, mode='patchGAN')
```

main.py

convert 的時候由於題目其中一個要求為 combine p1 和 p2，所以我們加了 test_combine function（如下圖），

```
107     def test_combine(self, x, c1, c2, gen=False):
108         self.set_eval()
109         x = to_var(x).permute(0, 2, 1)
110         enc = self.Encoder(x)
111         x_tilde = self.Decoder(enc, c1, c2)
112         return x_tilde.data.cpu().numpy()
```

(2) 在訓練完成後，試著將助教要求轉換的音檔轉成 source speaker 和 target speaker 的 interpolation，也就是在 testing 的時候，除了將指定的音檔轉成 p1 和 p2 的聲音之外，請嘗試轉成p1 和 p2 interpolation 的聲音。並比較分析 interpolated 的聲音和 p1 以及 p2 的關係。你可以從聲音頻率的高低、口音、語調等面向進行觀察。只要有合理分析助教就會給分。請同時將這題的音檔放在github 的 hw2-1資料夾中，檔名格式請參考投影片。(1.5%)

p1 轉 p2 有明顯的男變女的聲音轉換，但是兩者句子的語調有些許不同，而 p1 轉 p1&p2 interpolation 聲音會變高一點，參雜了比較多女生（p1）的聲音，而且語調也跟 p1 比較相進。

p2 轉 p1 也是一樣有明顯的女變男的聲音轉換，但句子語調沒有辦法百分之百一樣，然 p2 轉成 p1&p2 interpolation 可以明顯的聽到語調被修正回來，不過較可惜的是我們的 interpolation 似乎保留比較多女生的聲音資訊，因此轉換出來的結果主觀聽下來比較偏向女生的聲音。

口音方面，由於兩位 speaker 皆是英國強調，所以轉換前後並沒有感受到明顯的不同。

HW2-2 (GAN) (2.5%)

(1) 請使用助教在投影片中提到的連結，進行 voice conversion。請描述在這個程式碼中，語者資訊是如何被嵌入模型中的？請問這樣的方式有什麼優缺點？有沒有其他的作法可以將 speaker information 放入generator 裡呢？(1%)

連結中的方法將語者資訊轉成 one-hot vector，以 github 題供之範例為例：4 個 speaker 的資訊會以 1*4 的 one-hot vector 表示（若 target 為第 3 個語者，vector 中第3個值為1 其餘為 0）。one-hot vector 的方法很直觀且簡單，但有無法任意增減語者的問題，若想從 4 個與者轉換改成 6 個語者轉換模型就要重新訓練。speaker embedding 還有其他方式，例如 i-vector, d-vector, x-vector...等等。

(2) 請描述你如何將原本的程式碼改成訓練兩個語者的 voice conversion 程式。(0.5%)

由於 speaker 從 4 個變成 2 個，所以我們將 domain classifier 的 output 從維度為 4 的 vector 修改成維度 1（如圖1）。然後將 domain classifier 的 loss 改成 BCEWithLogitsLoss。（如圖2）

```python
class DomainClassifier(nn.Module):
    """docstring for DomainClassifier."""
    def __init__(self):
        super(DomainClassifier, self).__init__()
        #in_channel ,out_channel, kernel, stride, padding
        # self.main = nn.Sequential(
        #     Down2d(1, 8, (4,4), (2,2), (5,1)),
        #     Down2d(8, 16, (4,4), (2,2), (1,1)),
        #     Down2d(16, 32, (4,4), (2,2), (0,1)),
        #     Down2d(32, 16, (3,4), (1,2), (1,1)),
        #     nn.Conv2d(16, 4, (1,4), (1,2), (0,1)),
        #     nn.AvgPool2d((1,16)),
        #     nn.LogSoftmax()
        # )
        self.main = nn.Sequential(
            Down2d(1, 8, (4,4), (2,2), (5,1)),
            Down2d(8, 16, (4,4), (2,2), (1,1)),
            Down2d(16, 32, (4,4), (2,2), (0,1)),
            Down2d(32, 16, (3,4), (1,2), (1,1)),
            nn.Conv2d(16, 1, (1,4), (1,2), (0,1)),
            nn.AvgPool2d((1,16)),
            #nn.Sigmoid()
            #nn.LogSoftmax()
        )
    def forward(self, x):
        x = x[:, :, 0:8, :]
        x = self.main(x)
        x = x.view(x.size(0), x.size(1))
        return x
```

（圖一）

```python
            CELoss = nn.CrossEntropyLoss()
            BCELoss = nn.BCEWithLogitsLoss()
            cls_real = self.C(x_real)

            #cls_loss_real = CELoss(input=cls_real, target=speaker_idx_org)
            cls_loss_real = BCELoss(input=cls_real, target=speaker_idx_org)

            self.reset_grad()
            cls_loss_real.backward()
            self.c_optimizer.step()
            #Logging.
            loss = {}
            loss['C/C_loss'] = cls_loss_real.item()

            out_r = self.D(x_real, label_org)
            #Compute loss with fake audio frame.
            x_fake = self.G(x_real, label_trg)
            out_f = self.D(x_fake.detach(), label_trg)
            d_loss_t = F.binary_cross_entropy_with_logits(input=out_f,target=torch.zeros_like(out_f, dtype=torch.float)) + \
                F.binary_cross_entropy_with_logits(input=out_r, target=torch.ones_like(out_r, dtype=torch.float))

            out_cls = self.C(x_fake)
            d_loss_cls = BCELoss(input=out_cls, target=speaker_idx_trg)
```

（圖二）

(3) 請問這個程式碼中，input acoustic feature 以及 generator output 分別是什麼呢？ (1%) Hint: 請研究一下 preprocess 時做了哪些事情。

這個程式碼的 input acoustic feature 為 Mel Cepstral Coefficents (MCEP)，相較於 MFCC，MCEP 可以保留比較多的語音資訊，因此做語音合成時時常使用 MCEP 作為 acoustic feature。Generator 的 output 也是 MCEP acoustic

feautre，並且希望跟 input 出來的 features 一樣。比較不一樣的是 generator 在 decode 時 concat target labe 以加入語者資訊。

HW2-3 (1) 和 (2) 擇一回答 (4%)

(1) 請自己找一個不是 StarGAN-VC，也不是 HW2-1 的 model，實際 train 看看。請詳細描述 model 得架構， training objective，訓練時是否需要 paired data 等等。(4%) Hint: useful link

TTS without T:

我們試了助教給的link，也就是TTS without T。在這裡，我們修改了訊練資料，並且將語者改成了p1以及p2。改變的檔案如下：

```
model_path.add_argument('--hps_path', type=str, default='./hps/zerospeech_english.json', help='hyperparameter path, please refer to the default setti
model_path.add_argument('--ckpt_dir', type=str, default='./ckpt_english', help='checkpoint directory for training storage')
model_path.add_argument('--result_dir', type=str, default='./result_dlhlp', help='result directory for generating test results')
model_path.add_argument('--sub_result_dir', type=str, default='./dlhlp/', help='sub result directory for generating zerospeech synthesis results')
model_path.add_argument('--model_name', type=str, default='modelv3.pth', help='base model name for training')
# model_path.add_argument('--load_train_model_name', type=str, default='model.pth-ae-400000-128-multi-1024-english', help='the model to restore for t
model_path.add_argument('--load_train_model_name', type=str, default='modelv3.pth-s2-14700_savestep_trainal', help='the model to restore for training
model_path.add_argument('--load_test_model_name', type=str, default='modelv3.pth-s2-400', help='the model to restore for testing, all the --test_* co
model_path.add_argument('--ckpt_pth', type=str, default=None, help='the direct path to a model ckpt to restore for testing, all the --test_* commands
model_path.add_argument('--load_tclf_model_name', type=str, default=None, help='the model to restore for classifier')
args = parser.parse_args()
```

並且testing的檔案也改了。

```
data_path.add_argument('--dataset', choices=['english', 'surprise'], default='english', help='which dataset to use')
data_path.add_argument('--source_path', type=str, default='./data/dlhlp_2_2/train/p1/', help='the zerospeech train unit dataset')
data_path.add_argument('--target_path', type=str, default='./data/dlhlp_2_2/train/p2/', help='the zerospeech train voice dataset')
data_path.add_argument('--test_path', type=str, default='./data/dlhlp_2_2/test/', help='the zerospeech test dataset')
data_path.add_argument('--synthesis_list', type=str, default='./data/dlhlp_2_2/synthesis.txt', help='the zerospeech testing list')
data_path.add_argument('--dataset_path', type=str, default='./data/dlhlp_2_2/dataset_english.hdf5', help='the processed train dataset (unit + voice)')
data_path.add_argument('--index_path', type=str, default='./data/dlhlp_2_2/index_english.json', help='sample training segments from the train dataset, fo
data_path.add_argument('--index_source_path', type=str, default='./data/dlhlp_2_2/index_english_source.json', help='sample training source segments from
data_path.add_argument('--index_target_path', type=str, default='./data/dlhlp_2_2/index_english_target.json', help='sample training target segments from
data_path.add_argument('--speaker2id_path', type=str, default='./data/dlhlp_2_2/speaker2id_english.json', help='records speaker and speaker id')
data_path.add_argument('--multi2idx_path', type=str, default='./data/dlhlp_2_2/multi2idx.json', help='records encoding and idx mapping')
data_path.add_argument('--metadata_path', type=str, default='./data/dlhlp_2_2/metadata_english_target.csv', help='path to store encodings for Tacotron')
```

然後我們把語者的個數從原本的101改成了2個人。

最後便依循指示train了train_ae，train_tgat，train_al在老師所提供的dataset上面。

cVAE:

我們直接使用了 2-1 Encoder 和 Decoder 架構，並修改 Encoder 的部份。

```
    def reparametrize(self, mu, logvar, train=True):
        if train:
            std = torch.exp(0.5*logvar)
            eps = torch.randn_like(std)
            return eps*std + mu
        else:
            return mu

    def forward(self, x):
        aa=c.view(c.size(0), 1, 1)
        bb=aa.repeat(1, 1, x.size(2))
        x = torch.cat([x, bb.float()], 1)
        outs = []

        for l in self.conv1s:
            out = pad_layer(x, l)
            outs.append(out)

        out = torch.cat(outs + [x], dim=1)
        out = torch.cat([out, bb], dim=1)
        out = F.leaky_relu(out, negative_slope=self.ns)
        out = self.conv_block(out, [self.conv2], [self.ins_norm1, self.drop1], res=False)
        out = self.conv_block(out, [self.conv3, self.conv4], [self.ins_norm2, self.drop2])
        out = self.conv_block(out, [self.conv5, self.conv6], [self.ins_norm3, self.drop3])
        out = self.conv_block(out, [self.conv7, self.conv8], [self.ins_norm4, self.drop4])
        #dense layer
        out = self.dense_block(out, [self.dense1, self.dense2], [self.ins_norm5, self.drop5], res=True)
        out = self.dense_block(out, [self.dense3, self.dense4], [self.ins_norm6, self.drop6], res=True)
        out_rnn = RNN(out, self.RNN)
        out = torch.cat([out, out_rnn], dim=1)
        mu = linear(out, self.linear1)
        var = linear(out, self.linear2)

        mu = F.leaky_relu(mu, negative_slope=self.ns)
        var = F.leaky_relu(var, negative_slope=self.ns)
        mu = out[:,0:512,:]
        var = out[:, 512:,:]
        output = self.reparametrize(mu, var)
```

我們在 Encoder 的地方也加入了語者資訊，並最後改為輸出 mean 跟 std。

(2) 想辦法 improve HW2-1或是 HW2-2 的 model (或是改一些有趣的東西)。Hint: 各位可以想想看 speaker embedding 有沒有什麼其他方式？如果今天我在 testing 的時候想要讓他有 unseen speaker 也可以成功轉過去的話，用什麼 embedding會比較好？(hint: d-vector, i-vector) 又或者要怎麼把這個 speaker embedding 餵進 model 裡面呢？有什麼不同的方法？

CycleGAN-VC2:

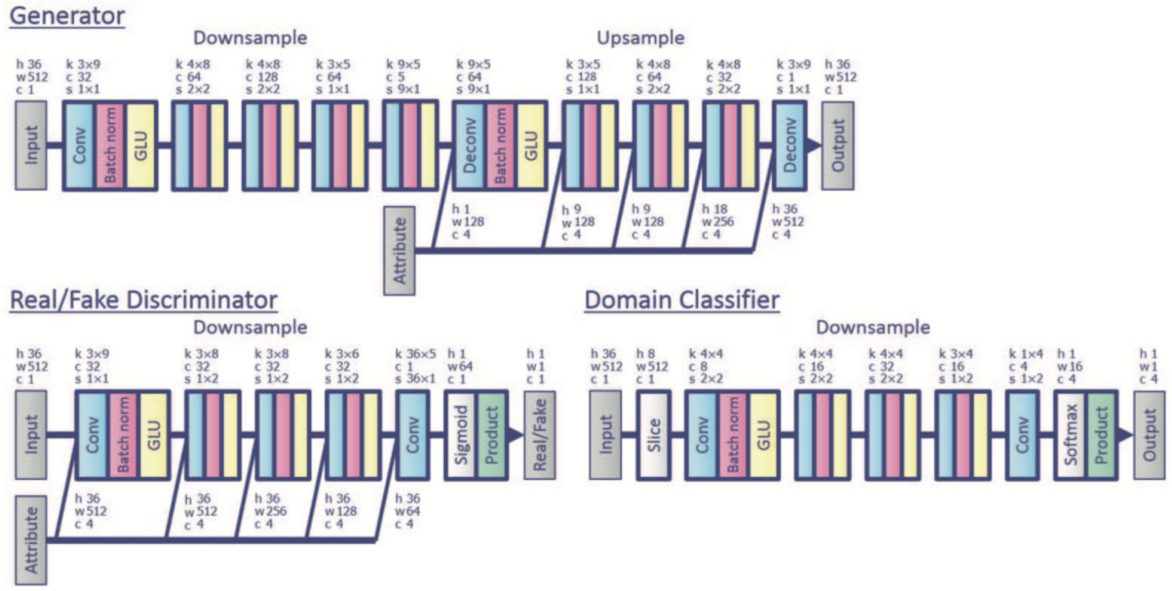

圖（一）：hw2-2的架構

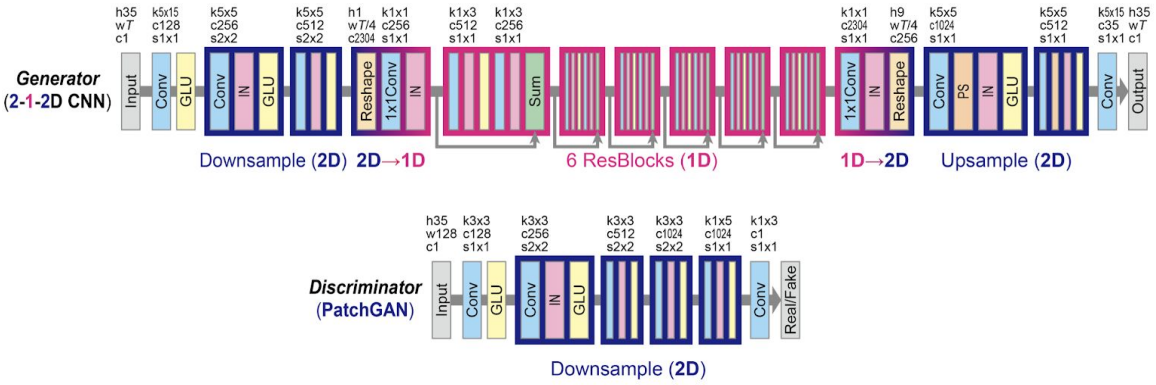

圖（二）：hw2-3的架構

這個方法是根據hw2-2的model做修改，因為hw2-2只用了兩個語者做訓練，基本上可以看作是一個CycleGAN。

這個方法跟hw2-2的StarGAN（見圖一）差別在於Generator具有2D-1D-2D CNN結構，而不是基於2D CNN的結構。

在這個網絡（見圖二）中，將2D卷積用於下採樣和上採樣，並將1D卷積用於主轉換過程（即residual blocks），並用1x1 convolution調整channel數目（見圖三）。

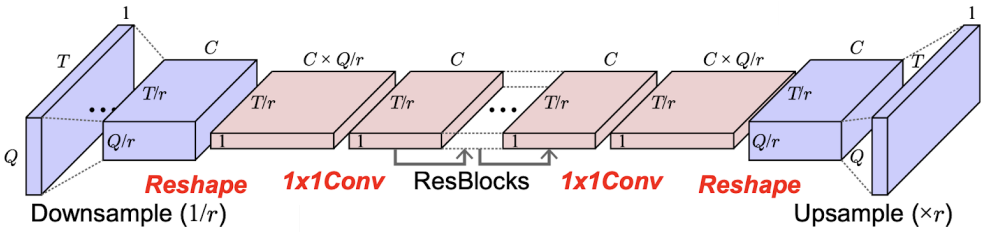

圖（三）：2D-1D-2D CNN結構

最後，將domain classifier拿掉。

```
156  class Generator(nn.Module):
157      def __init__(self):
158          super(Generator, self).__init__()
159
160          self.conv1 = nn.Conv2d(in_channels=1,
161                                 out_channels=128,
162                                 kernel_size=[5,15],
163                                 stride=1,
164                                 padding=[2,7])
165
166          self.conv1_gates = nn.Conv2d(in_channels=1,
167                                 out_channels=128,
168                                 kernel_size=[5,15],
169                                 stride=1,
170                                 padding=[2,7])
171
172          # Downsample Layer
173          self.downSample1 = downSample_Generator(in_channels=128,
174                                                  out_channels=256,
175                                                  kernel_size=5,
176                                                  stride=2,
177                                                  padding=2)
178
179          self.downSample2 = downSample_Generator(in_channels=256,
180                                                  out_channels=512,
181                                                  kernel_size=5,
182                                                  stride=2,
183                                                  padding=2)
184          #reshape
185          self.conv2 = nn.Conv1d(in_channels=3072,
186                                 out_channels=512,
187                                 kernel_size=1,
188                                 stride=1)
```

```
        # Residual Blocks
        self.residualLayer1 = ResidualLayer(in_channels=512,
                                            out_channels=1024,
                                            kernel_size=3,
                                            stride=1,
                                            padding=1)
        self.residualLayer2 = ResidualLayer(in_channels=512,
                                            out_channels=1024,
                                            kernel_size=3,
                                            stride=1,
                                            padding=1)
        self.residualLayer3 = ResidualLayer(in_channels=512,
                                            out_channels=1024,
                                            kernel_size=3,
                                            stride=1,
                                            padding=1)
        self.residualLayer4 = ResidualLayer(in_channels=512,
                                            out_channels=1024,
                                            kernel_size=3,
                                            stride=1,
                                            padding=1)
        self.residualLayer5 = ResidualLayer(in_channels=512,
                                            out_channels=1024,
                                            kernel_size=3,
                                            stride=1,
                                            padding=1)
        self.residualLayer6 = ResidualLayer(in_channels=512,
                                            out_channels=1024,
                                            kernel_size=3,
                                            stride=1,
                                            padding=1)
```

```
        #reshape
        self.conv3 = nn.Conv1d(in_channels=512,
                               out_channels=3072,
                               kernel_size=1,
                               stride=1)


        # UpSample Layer
        self.upSample1 = upSample_Generator(in_channels=512,
                                            out_channels=1024,
                                            kernel_size=5,
                                            stride=1,
                                            padding=2)

        self.upSample2 = upSample_Generator(in_channels=1024,
                                            out_channels=512,
                                            kernel_size=5,
                                            stride=1,
                                            padding=2)

        self.lastConvLayer = nn.Conv2d(in_channels=512,
                                       out_channels=1,
                                       kernel_size=[5,15],
                                       stride=1,
                                       padding=[2,7])
```